

Pagina 1

Questa e una pagina di esempio per testare il sistema RAG.
Il sistema estrae testo dai PDF, lo suddivide in chunk
e indicizza gli embedding in un database vettoriale Qdrant.

L intelligenza artificiale simula processi cognitivi umani
mediante sistemi informatici avanzati.

Componenti principali:

- FastAPI: framework web ad alte prestazioni
- LangChain + LangGraph: orchestrazione RAG
- Qdrant: database vettoriale coseno
- PostgreSQL: metadati e storico conversazioni

Flusso RAG:

1. Ricezione domanda utente
2. Embedding della query
3. Ricerca semantica top-k in Qdrant
4. Costruzione prompt con contesto
5. Risposta LLM

Tecnologie e Deployment

Pagina 3

Il progetto usa Python 3.11 e Docker Compose.
OpenAI GPT-4o-mini e il modello LLM predefinito.
text-embedding-3-small genera vettori 1536-dimensionali.

Per avviare il progetto:
`docker compose up`

Swagger UI disponibile su <http://localhost:8000/docs>